切诺夫不等式

总量偏离平均的概率，能有多小?

随机变量取值估计：马尔可夫 · 切比雪夫 · **切诺夫**

定理与符号 · 三界对比 · 原理与应用

切诺夫不等式：独立小贡献之和的集中保证

设 n 个随机变量 $X_1, ..., X_n$ **相互独立**，各取值于 $[0, 1]$；**不要求同分布**。 总量为 X，总量的期望为 μ（读作“缪”），E 表示取期望：

$$X = \sum_{i=1}^{n} X_i, \quad \mu = \mathrm{E}[X] = \sum_{i=1}^{n} \mathrm{E}[X_i] > 0.$$

若各项只取 0 或 1：记 $p_i = \Pr(X_i = 1)$，**各次概率可以不同**， 此时 $\mu = \sum_{i=1}^{n} p_i$。只有所有 $p_i = p$ 时，才简化为 $\mu = np$。

当相对偏差 $0 < \delta \leq 1$ 时，上尾界可写成以下**分母为 3 的简式**：

$$\Pr(X \geq (1+\delta)\mu) \leq e^{-\frac{\mu\delta^2}{3}}.$$

Pr 表示事件的概率，$e \approx 2.718$。$\delta > 0$ 表示向上偏离；**$\delta \leq 1$ 是此简式的适用范围**，偏差更大仍有切诺夫界，见后面的代入页。

拆解公式：单次概率与总量期望是什么关系？

以 **40 次独立公平抛掷** 为例：这是各次概率恰好相同的情形。

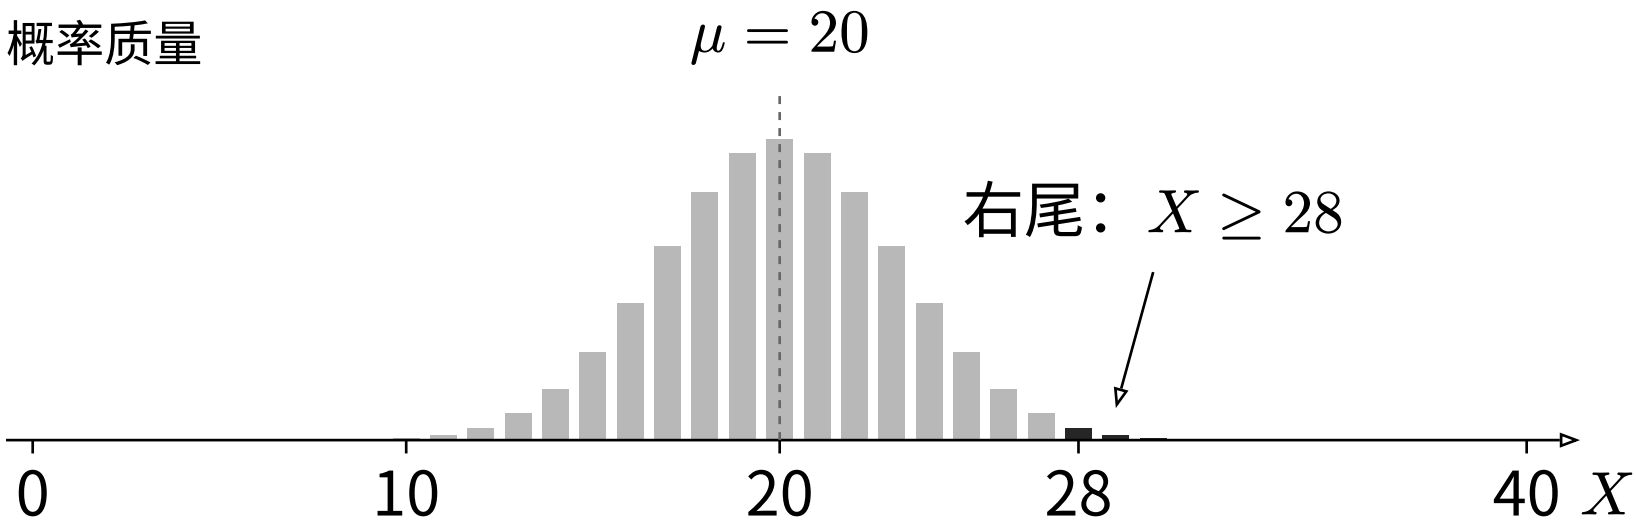
符号	角色 / 含义	抛硬币时的对应
n、i	项数、其中一项的编号	$n = 40$，$i = 1, \ldots, 40$
X_i	一次随机贡献	正面记 1，反面记 0
$p_i = \Pr(X_i = 1)$	第 i 次取到 1 的概率	本例各 $p_i = p = \frac{1}{2}$
$X = \sum_{i=1}^{n} X_i$	所有贡献的总和	40 次中的正面总次数
$\mu = \mathrm{E}[X]$	总量的期望，读作“缪”	$\mu = np = 40 \times \frac{1}{2} = 20$ 次

0/1 变量有 $\mathrm{E}[X_i] = 1 \times p_i + 0 \times (1 - p_i) = p_i$，所以 $\mu = \sum_{i=1}^{n} p_i$。

p_i 是单次概率，μ 是期望次数，$\sum$ 表示求和。**同概率是本例的选择，不是定理的要求。**

看见“尾部”：我们真正想控制的区域

仍是 **40 次独立公平抛掷**，$\mu = 20$；关注 $28 = (1 + 0.4) \times 20$，即 $\delta = 0.4$ 的上尾。



每根柱子对应一个次数的概率；右侧深色柱子**加起来**，就是 $\Pr(X \geq 28)$。

读懂偏差与概率：把公式代入一次

把实验增加到 **1000 次独立公平抛掷**；正面总数 X 的期望为 $\mu = 500$。 关心事件：正面 **至少出现 600 次**。

- 绝对偏差：$t = 600 - 500 = 100$ 次。
- 相对偏差：$\delta = \frac{t}{\mu} = \frac{100}{500} = 0.2$，即比平均多 **20%**。
- 因此 $600 = (1+\delta)\mu$，且 $0 < \delta \le 1$，可以代入。

$$\Pr(X \ge 600) \le e^{-\frac{500\times 0.2^2}{3}} \approx 0.00127 = 0.127\%.$$

右边是上界，不是实际概率；δ 是相对偏差，不是概率，可以大于 1。

双侧界：两侧相加后，还做了一次放宽

设 X 为独立 $[0,1]$ 变量之和，$\mu = \mathrm{E}[X] > 0$；本页取 $0 < \delta < 1$。

上尾的概率上界

$$\Pr(X \geq (1+\delta)\mu) \leq e^{-\frac{\mu\delta^2}{3}}$$

下尾的概率上界

$$\Pr(X \leq (1-\delta)\mu) \leq e^{-\frac{\mu\delta^2}{2}}$$

两侧事件互斥，先加真实概率，再分别代入上界：

$$\begin{aligned}\Pr(|X-\mu| \geq \delta\mu) &= \Pr(X \geq (1+\delta)\mu) + \Pr(X \leq (1-\delta)\mu) \\ &\leq e^{-\frac{\mu\delta^2}{3}} + e^{-\frac{\mu\delta^2}{2}} \\ &\leq 2e^{-\frac{\mu\delta^2}{3}}.\end{aligned}$$

因为 $e^{-\frac{\mu\delta^2}{2}} \leq e^{-\frac{\mu\delta^2}{3}}$，可把较小的下尾界放大。**最后一步是“至多”，不是“等于”；保留两个不同项相加，会得到更紧的界。**

证明思路：切诺夫界为什么成立？

沿用定理条件，取 $0 < \delta \le 1$。令阈值 $a = (1+\delta)\mu$；$\lambda > 0$ 是可选择的辅助参数。

① 指数变换，再用马尔可夫：把概率转成期望的上界。

$$\Pr(X \ge a) = \Pr\left(e^{\lambda X} \ge e^{\lambda a}\right) \le e^{-\lambda a}\,\mathrm{E}\left[e^{\lambda X}\right].$$

② 独立性使期望可以拆开；每项取值在 $[0,1]$，使乘积有上界。

$$\mathrm{E}\left[e^{\lambda X}\right] = \mathrm{E}\left[e^{\lambda X_1}\right] \times \ldots \times \mathrm{E}\left[e^{\lambda X_n}\right] \le e^{\mu(e^{\lambda}-1)}.$$

③ 选 $\lambda = \ln(1+\delta)$，代回前两步，再放宽成常用简式。

$$\Pr(X \ge (1+\delta)\mu) \le e^{-\mu((1+\delta)\ln(1+\delta)-\delta)} \le e^{-\frac{\mu\delta^2}{3}}.$$

ln 是自然对数。最后一步使用 $(1+\delta)\ln(1+\delta) - \delta \ge \frac{\delta^2}{3}$（$0 < \delta \le 1$）；具体代数推导省略。

三种不等式：使用的信息不同，保证也不同

工具	适用条件 / 所用信息	常用表达式
马尔可夫	$X \geq 0$，有限期望；$a > 0$	$\Pr(X \geq a) \leq \frac{\mu}{a}$
切比雪夫	有限方差 σ^2；$t > 0$	$\Pr(\lvert X - \mu \rvert \geq t) \leq \frac{\sigma^2}{t^2}$
切诺夫（本课版本）	独立 $[0,1]$ 项之和；$\mu > 0$，$0 < \delta \leq 1$	$\Pr(X \geq (1+\delta)\mu) \leq e^{-\frac{\mu\delta^2}{3}}$

$\mu = \mathrm{E}[X]$，$\sigma^2 = \mathrm{Var}(X) = \mathrm{E}[(X-\mu)^2]$ 衡量波动；a 是阈值，$t = \delta\mu$ 是绝对偏差。

切诺夫利用**独立、有界的求和结构**得到指数界；马尔可夫和切比雪夫不要求这种结构，适用范围更宽。

同一个问题，三种上界

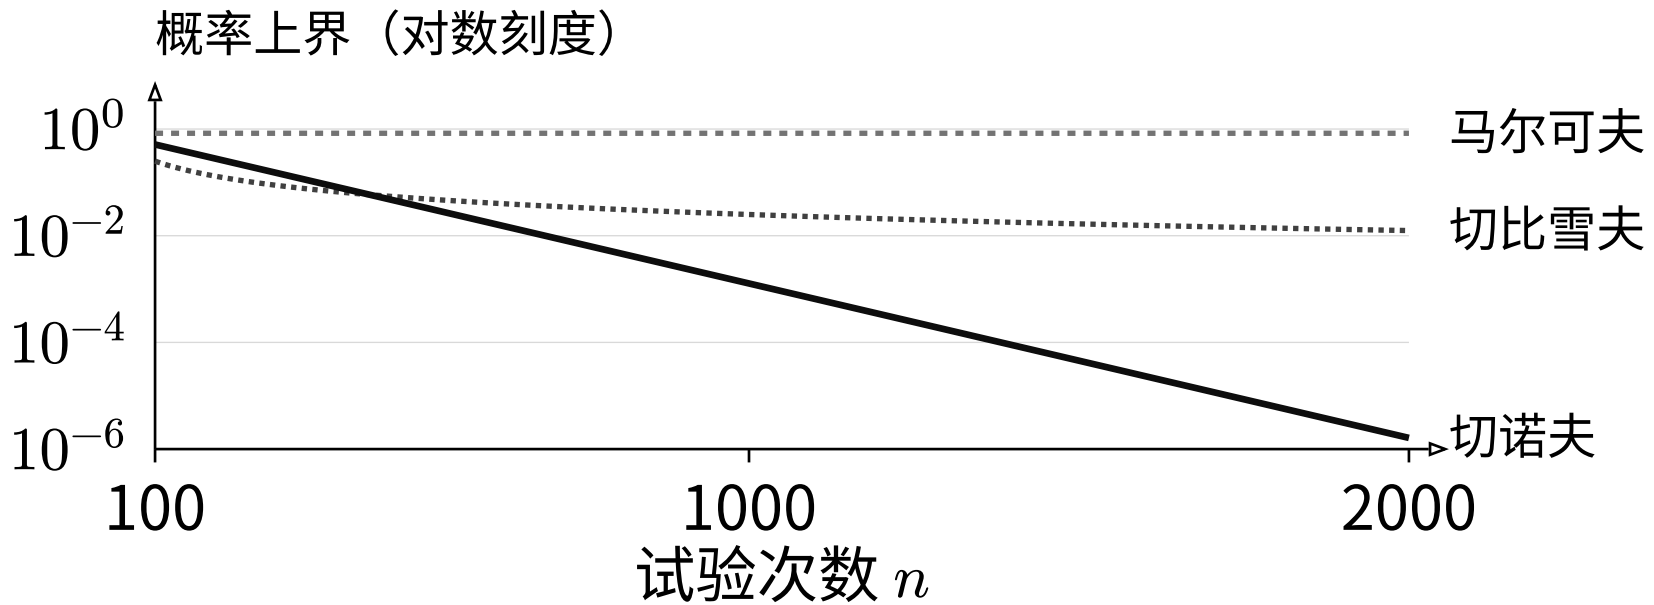
独立抛 1000 次公平硬币：$\mu = 500$，$\mathrm{Var}(X) = 250$。估计 **同一事件** $\Pr(X \geq 600)$，此时 $t = 100$、$\delta = 0.2$。

工具	代入计算	概率上界
马尔可夫	$\frac{\mathrm{E}[X]}{600} = \frac{500}{600}$	≈ 0.8333
切比雪夫	$\Pr(X \geq 600) \leq \Pr(\lvert X - 500 \rvert \geq 100) \leq \frac{250}{100^2}$	0.025
切诺夫（上尾）	$e^{-\frac{500 \times 0.2^2}{3}}$	≈ 0.00127

本例中，更充分地使用独立、有界的结构，得到更小的上界。

固定相对偏差：指数下降意味着什么？

独立抛 n 次公平硬币，比较“正面至少占 60%”的概率上界。



纵轴为 1、0.01、0.0001……；每向下一个刻度，概率上界小 100 倍。

三条界为 $\frac{5}{6}$、$\frac{25}{n}$、$e^{-\frac{n}{150}}$：常数、反比、指数下降。小 n 时，简化切诺夫界不一定最紧。

动机：用可接受的风险，决定投入多少资源

“平均还不错”不足以决定是否采用一个算法：一次运行也可能明显偏离平均。

正向评估
给定重复次数或容量，
估计失败概率有多大。

反向设计
先要求失败概率低于 1%，
再求需要多少次、多少容量。

切诺夫界直接给出**概率上界**；算法设计用它确定**重复次数、样本量和容量余量**。

上界小于目标，就得到一个充分保证；上界较大，只说明这次分析还不能保证达标。

抽样估计：用风险要求反求样本量

要估计数据库中某类记录的比例 p；假设事先知道 $p \geq 0.2$。 独立、均匀、有放回地抽取 n 条，X 为命中数，样本比例为 $\hat{p} = \frac{X}{n}$。

目标：相对误差达到 20% 的概率，不超过 1%。

$$\Pr(|\hat{p} - p| \geq 0.2p) \leq 2e^{-\frac{np \times 0.2^2}{3}} \leq 2e^{-\frac{n}{375}}$$

令右边不超过 0.01，取 $\boldsymbol{n = 1987}$ 即可。 算法由此得到一个有保证的抽样规模。

这是充分样本量。若不知道 p 的正下界，不能照搬这个数字；20% 相对误差也不等于 20 个百分点。

负载均衡：平均每台 100 项，该预留多少？

把 **10 000 项任务独立、均匀**分到 100 台服务器，单台负载 L 的期望为 $\mu = 100$。 每项占一个容量单位；保守地把“达到容量”就记为风险。

先界定单台风险，再相加，控制“任意一台达到容量”的风险：

$$\Pr(\text{至少一台达到容量}) \le 100e^{-\frac{100\delta^2}{3}}.$$

每台容量	相对余量 δ	整体风险上界
150 项	0.5	$\approx 2.40\%$
160 项	0.6	$\approx 0.0614\%$

要求整体风险低于 **0.1%**：160 项容量能得到保证；150 项的这个界不足以保证达标。

参考资料

1. Alistair Sinclair，Berkeley CS174，**Chernoff/Hoeffding Bounds & Randomized Routing**。 上下尾的标准形式、参数范围与应用
2. Gautam Kamath，**CS761, Lecture 2**。 矩母函数与切诺夫界的推导思路
3. Tim Roughgarden，Stanford CS261，**Lecture 18**。 散列、并合界与随机舍入

课件采用独立 $[0,1]$ 变量之和的乘法型简式。数值例子中的概率值是上界，样本量和容量是充分条件。